


# Dopasowanie modelu ARIMA do szeregu gnp

Paweł Matłowski i Michał Liszkowski

20 06 2021

## Podział danych na część uczącą i testową

```
training_set <- window(df, end = c(1990,4))  
testing_set <- window(df, start = c(1991,1))  
autoplot(cbind(testing_set, training_set))
```




## Przekształcenie do postaci stacjonarnej szeregu

```
lambda <- BoxCox.lambda(training_set)  
ndiffs(training_set)
```

```
## [1] 2
```

```
training_set_stat <- diff(training_set, differences = 2)
training_set_stat <- BoxCox(training_set_stat, lambda = lambda)
autoplot(training_set_stat)
```



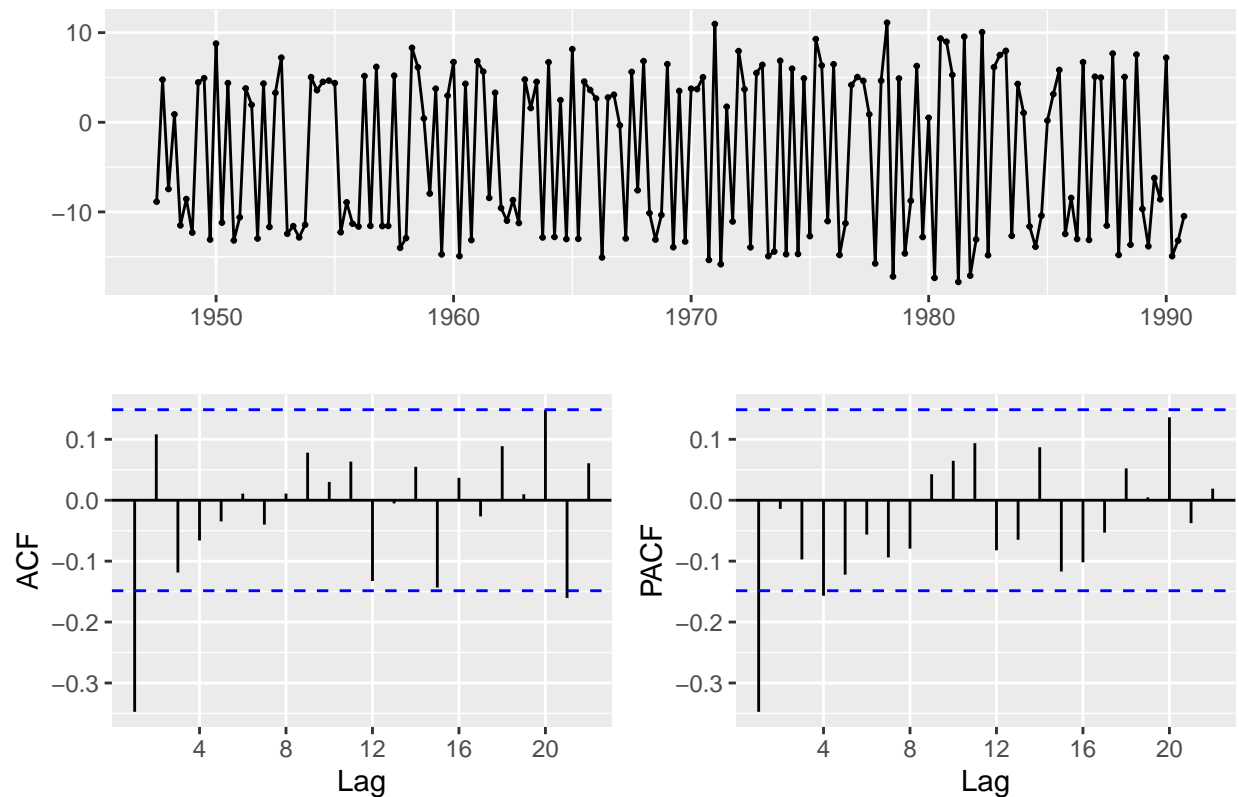
```
Box.test(training_set_stat)
```

```
##
## Box-Pierce test
##
## data: training_set_stat
## X-squared = 20.99, df = 1, p-value = 4.617e-06
```

## Wstępna identyfikacja modeli stacjonarnych

### Wybór AR i MA na podstawie ACF i PACF

```
ggtsdisplay(training_set_stat)
```



```
ma21.fit <- Arima(training_set, order = c(0,1,21))
ar20.fit <- Arima(training_set, order = c(20,1,0))
```

Na podstawie wykresów funkcji autokorelacji i funkcji cząstkowej autokorelacji będę rozważał w dalszych etapach nasz szereg jako szereg  $MA(21)$  lub  $AR(20)$ .

## Wybór rzędów dla modeli ARMA na podstawie kryteriów informacyjnych

```
arima.fit <- auto.arima(training_set)
arima.fit
```

```
## Series: training_set
## ARIMA(1,2,1)(0,0,2)[4]
##
## Coefficients:
##      ar1      ma1      sma1      sma2
##      0.3440 -0.9717 -0.0323 -0.1348
## s.e.  0.0759  0.0196  0.0793  0.0717
##
## sigma^2 estimated as 1345:  log likelihood=-872.97
## AIC=1755.94  AICc=1756.3  BIC=1771.74
```

Automatyczne dopasowanie dało nam model  $ARMA(1,2,1)$


# Badanie poprawności dopasowania modeli na podstawie analizy reszt

## MA(21)


```
test(residuals(ma21.fit))
```

```
## Null hypothesis: Residuals are iid noise.
## Test          Distribution Statistic p-value
## Ljung-Box Q    Q ~ chisq(20)      4.71  0.9998
## McLeod-Li Q    Q ~ chisq(20)     31.71  0.0465 *
## Turning points T (T-116)/5.6 ~ N(0,1) 120  0.4723
## Diff signs S    (S-87.5)/3.8 ~ N(0,1)  92  0.2413
## Rank P          (P-7700)/390.8 ~ N(0,1) 8102 0.3036
```


**ACF**




**PACF**




**Residuals**



**Normal Q-Q Plot**



```
tsdiag(ma21.fit)
```

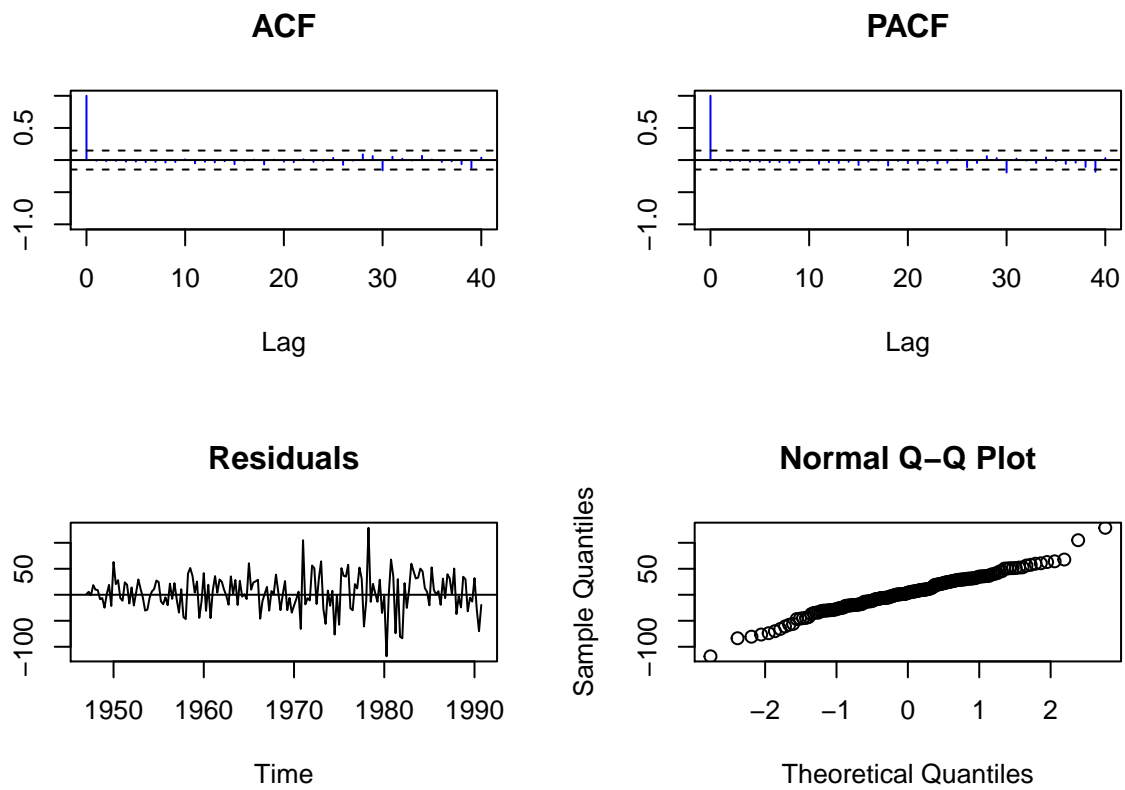


Analizując reszty dla tego modelu, nie mamy podstaw do odrzucenia hipotezy zerowej, że reszty są szumem i.i.d, zatem model nasz wydaje się być sensownym dopasowaniem.


## AR(20)

```
test(residuals(ar20.fit))
```

```
## Null hypothesis: Residuals are iid noise.
## Test          Distribution Statistic  p-value
## Ljung-Box Q    Q ~ chisq(20)      3.99      1
## McLeod-Li Q    Q ~ chisq(20)     46.77    6e-04 *
## Turning points T (T-116)/5.6 ~ N(0,1) 122    0.2809
## Diff signs S    (S-87.5)/3.8 ~ N(0,1)  83    0.2413
## Rank P          (P-7700)/390.8 ~ N(0,1) 7802    0.7941
```



```
tsdiag(ar20.fit)
```







Analizując reszty dla tego modelu, nie mamy podstaw do odrzucenia hipotezy zerowej, że reszty są szumem i.i.d, zatem model nasz wydaje się być sensownym dopasowaniem.

## ARMA(1,2,1)


```
test(residuals(arima.fit))
```

```
## Null hypothesis: Residuals are iid noise.
## Test          Distribution Statistic  p-value
## Ljung-Box Q    Q ~ chisq(20)      23.4    0.2697
## McLeod-Li Q    Q ~ chisq(20)      54.88    0 *
## Turning points T (T-116)/5.6 ~ N(0,1) 125    0.1058
## Diff signs S   (S-87.5)/3.8 ~ N(0,1)  92    0.2413
## Rank P         (P-7700)/390.8 ~ N(0,1) 8008    0.4306
```



```
tsdiag(arima.fit)
```





Analizując reszty dla tego modelu, nie mamy podstaw do odrzucenia hipotezy zerowej, że reszty są szumem i.i.d, zatem model nasz wydaje się być sensownym dopasowaniem.

## Porównanie jakości dopasowania modeli w oparciu o kryteria informacyjne

```
AIC(ma21.fit)
```

```
## [1] 1790.639
```

```
AIC(ar20.fit)
```

```
## [1] 1782.12
```

```
AIC(arima.fit)
```

```
## [1] 1755.943
```

```
AIC(ma21.fit, k = log(length(training_set_stat)))
```

```
## [1] 1860.139
```

```
AIC(ar20.fit, k = log(length(training_set_stat)))
```

```
## [1] 1848.46
```

```
AIC(arima.fit, k = log(length(training_set_stat)))
```

```
## [1] 1771.738
```

Widzimy, że wśród wszystkich kryteriów model dopasowany automatycznie przez funkcję *auto.arima* ma najlepsze wyniki.

## Ocena istotności współczynników

### MA(21)

```
coeftest(ma21.fit)

##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ma1    0.412912   0.076316   5.4105 6.283e-08 ***
## ma2    0.358904   0.110657   3.2434 0.001181 **
## ma3    0.236163   0.089005   2.6534 0.007969 **
## ma4    0.174528   0.105764   1.6502 0.098909 .
## ma5    0.137494   0.099844   1.3771 0.168483
## ma6    0.197594   0.109913   1.7977 0.072219 .
## ma7    0.083705   0.096611   0.8664 0.386264
## ma8   -0.096193   0.103754  -0.9271 0.353862
## ma9    0.089847   0.101225   0.8876 0.374754
## ma10   0.248564   0.093884   2.6476 0.008107 **
## ma11   0.207346   0.093414   2.2197 0.026442 *
## ma12  -0.021998   0.089644  -0.2454 0.806156
## ma13   0.106205   0.106324   0.9989 0.317854
## ma14   0.080004   0.087093   0.9186 0.358303
## ma15  -0.122626   0.091451  -1.3409 0.179954
## ma16   0.151182   0.095623   1.5810 0.113873
## ma17   0.141965   0.085679   1.6569 0.097530 .
## ma18   0.044468   0.104323   0.4263 0.669921
## ma19   0.052982   0.107822   0.4914 0.623154
## ma20   0.277125   0.100258   2.7641 0.005708 **
## ma21   0.148790   0.078815   1.8878 0.059048 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Funkcja *coeftest* pokazuje nam, że dla modelu *MA*(21) powinniśmy usunąć zmienne 1, 2, 3, 10, 11, 12.

Sprawdźmy, jak wyzerowanie współczynników wpłynie na model.

```
ma.fixed <- numeric(21)
ma.fixed[1] <- NA
ma.fixed[2] <- NA
ma.fixed[3] <- NA
ma.fixed[10] <- NA
ma.fixed[11] <- NA
ma.fixed[20] <- NA

ma.zeros <- Arima(training_set, order=c(0,1,21), fixed=ma.fixed)
ma.zeros

## Series: training_set
## ARIMA(0,1,21)
##
```

```
## Coefficients:
##      ma1      ma2      ma3      ma4      ma5      ma6      ma7      ma8      ma9      ma10      ma11
##      0.4182 0.2843 0.1482      0      0      0      0      0      0 0.1771 0.1518
## s.e. 0.0806 0.0743 0.0744      0      0      0      0      0      0 0.0799 0.0716
##      ma12      ma13      ma14      ma15      ma16      ma17      ma18      ma19      ma20      ma21
##      0      0      0      0      0      0      0      0 0.1741      0
## s.e. 0      0      0      0      0      0      0      0 0.0746      0
##
## sigma^2 estimated as 1491: log likelihood=-885.35
## AIC=1784.71 AICc=1785.38 BIC=1806.86
```

```
ma21.fit
```

```
## Series: training_set
## ARIMA(0,1,21)
##
## Coefficients:
##      ma1      ma2      ma3      ma4      ma5      ma6      ma7      ma8      ma9
##      0.4129 0.3589 0.2362 0.1745 0.1375 0.1976 0.0837 -0.0962 0.0898
## s.e. 0.0763 0.1107 0.0890 0.1058 0.0998 0.1099 0.0966 0.1038 0.1012
##      ma10      ma11      ma12      ma13      ma14      ma15      ma16      ma17      ma18
##      0.2486 0.2073 -0.0220 0.1062 0.0800 -0.1226 0.1512 0.1420 0.0445
## s.e. 0.0939 0.0934 0.0896 0.1063 0.0871 0.0915 0.0956 0.0857 0.1043
##      ma19      ma20      ma21
##      0.0530 0.2771 0.1488
## s.e. 0.1078 0.1003 0.0788
##
## sigma^2 estimated as 1378: log likelihood=-873.32
## AIC=1790.64 AICc=1797.3 BIC=1860.26
```

Widzimy, że według kryterium AIC model po usunięciu zmiennych ma trochę lepsze własności, a więc dalej będziemy używać modelu zmodyfikowanego do prognoz.

```
subsection{AR(20)}
```

```
coeftest(ar20.fit)
```

```
##
## z test of coefficients:
##
##      Estimate Std. Error z value Pr(>|z|)
## ar1  0.3913343 0.0752289 5.2019 1.972e-07 ***
## ar2  0.1252265 0.0814110 1.5382 0.12400
## ar3  0.0336752 0.0812134 0.4147 0.67840
## ar4  0.0408706 0.0815604 0.5011 0.61630
## ar5 -0.0365426 0.0799969 -0.4568 0.64781
## ar6  0.0513473 0.0798643 0.6429 0.52027
## ar7 -0.0682383 0.0794150 -0.8593 0.39020
## ar8 -0.0623600 0.0790509 -0.7889 0.43019
## ar9  0.1595073 0.0781678 2.0406 0.04129 *
## ar10 0.0585325 0.0789016 0.7418 0.45818
## ar11 0.0955476 0.0795091 1.2017 0.22947
## ar12 -0.1725610 0.0791996 -2.1788 0.02935 *
## ar13 0.0551535 0.0809056 0.6817 0.49543
## ar14 0.0086723 0.0807641 0.1074 0.91449
## ar15 -0.1069655 0.0802360 -1.3331 0.18249
## ar16 0.1892501 0.0803355 2.3557 0.01849 *
```

```
## ar17 0.0035914 0.0819753 0.0438 0.96506
## ar18 0.1004416 0.0819682 1.2254 0.22044
## ar19 -0.0357851 0.0819836 -0.4365 0.66248
## ar20 0.0798473 0.0762591 1.0471 0.29508
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Funkcja *coefstest* pokazuje nam, że dla modelu  $AR(20)$  powinniśmy usunąć zmienne 1, 9, 12, 16.

Sprawdźmy, jak wyzerowanie współczynników wpłynie na model.

```
ar.fixed <- numeric(20)
ar.fixed[1] <- NA
ar.fixed[9] <- NA
ar.fixed[12] <- NA
ar.fixed[16] <- NA

ar.zeros <- Arima(training_set, order=c(0,1,20), fixed=ar.fixed)
ar.zeros
```

```
## Series: training_set
## ARIMA(0,1,20)
##
## Coefficients:
##          ma1 ma2 ma3 ma4 ma5 ma6 ma7 ma8          ma9 ma10 ma11          ma12
##          0.3920  0  0  0  0  0  0  0  0 0.1433  0  0 0.0241
## s.e. 0.0611  0  0  0  0  0  0  0  0 0.0687  0  0 0.0728
##          ma13 ma14 ma15          ma16 ma17 ma18 ma19 ma20
##          0  0  0 0.1562  0  0  0  0
## s.e. 0  0  0 0.0664  0  0  0  0
##
## sigma^2 estimated as 1736: log likelihood=-899.44
## AIC=1808.88 AICc=1809.23 BIC=1824.7
```

```
ar20.fit

## Series: training_set
## ARIMA(20,1,0)
##
## Coefficients:
##          ar1          ar2          ar3          ar4          ar5          ar6          ar7          ar8          ar9
##          0.3913 0.1252 0.0337 0.0409 -0.0365 0.0513 -0.0682 -0.0624 0.1595
## s.e. 0.0752 0.0814 0.0812 0.0816 0.0800 0.0799 0.0794 0.0791 0.0782
##          ar10          ar11          ar12          ar13          ar14          ar15          ar16          ar17          ar18
##          0.0585 0.0955 -0.1726 0.0552 0.0087 -0.1070 0.1893 0.0036 0.1004
## s.e. 0.0789 0.0795 0.0792 0.0809 0.0808 0.0802 0.0803 0.0820 0.0820
##          ar19          ar20
##          -0.0358 0.0798
## s.e. 0.0820 0.0763
##
## sigma^2 estimated as 1354: log likelihood=-870.06
## AIC=1782.12 AICc=1788.16 BIC=1848.58
```

W tym przypadku zmodyfikowany model ma gorsze własności według kryteriów informacyjnych.


## Wnioski na podstawie przeprowadzonej diagnostyki modeli ARIMA

Z trzech rozważanych modeli, zdecydowanie najlepszym kandydatem jest model  $ARMA(1, 2, 1)$ , którego wybór sugeruje zarówno analiza reszt, jak i kryteria AIC oraz BIC, zaraz potem  $AR(20)$ , a najmniej odpowiedni jest  $MA(21)$ .

## Zastosowanie modeli do konstrukcji prognoz dla zbioru testowego

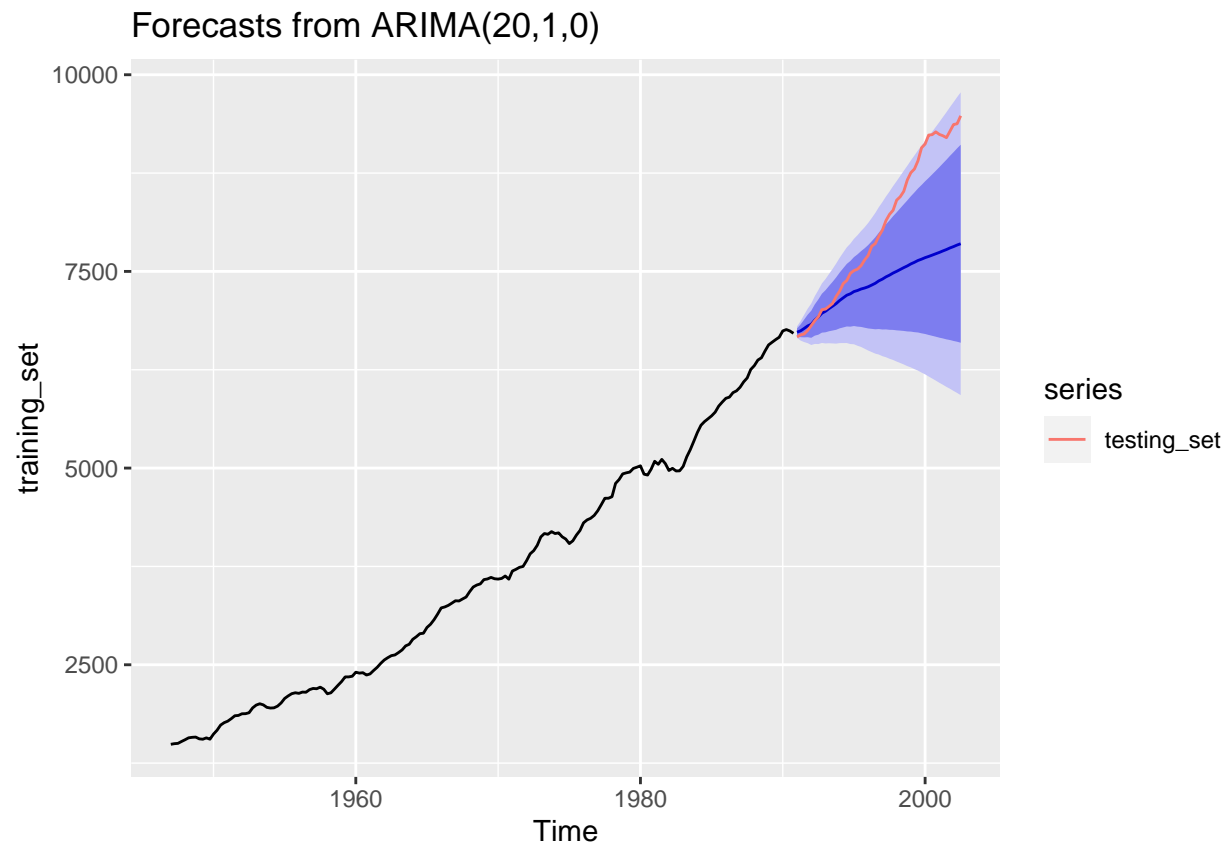
### MA(21)

```
h <- length(testing_set)
ma21.forecast <- forecast::forecast(ma.zeros, h = h)
autoplot(ma21.forecast) + autolayer(testing_set)
```



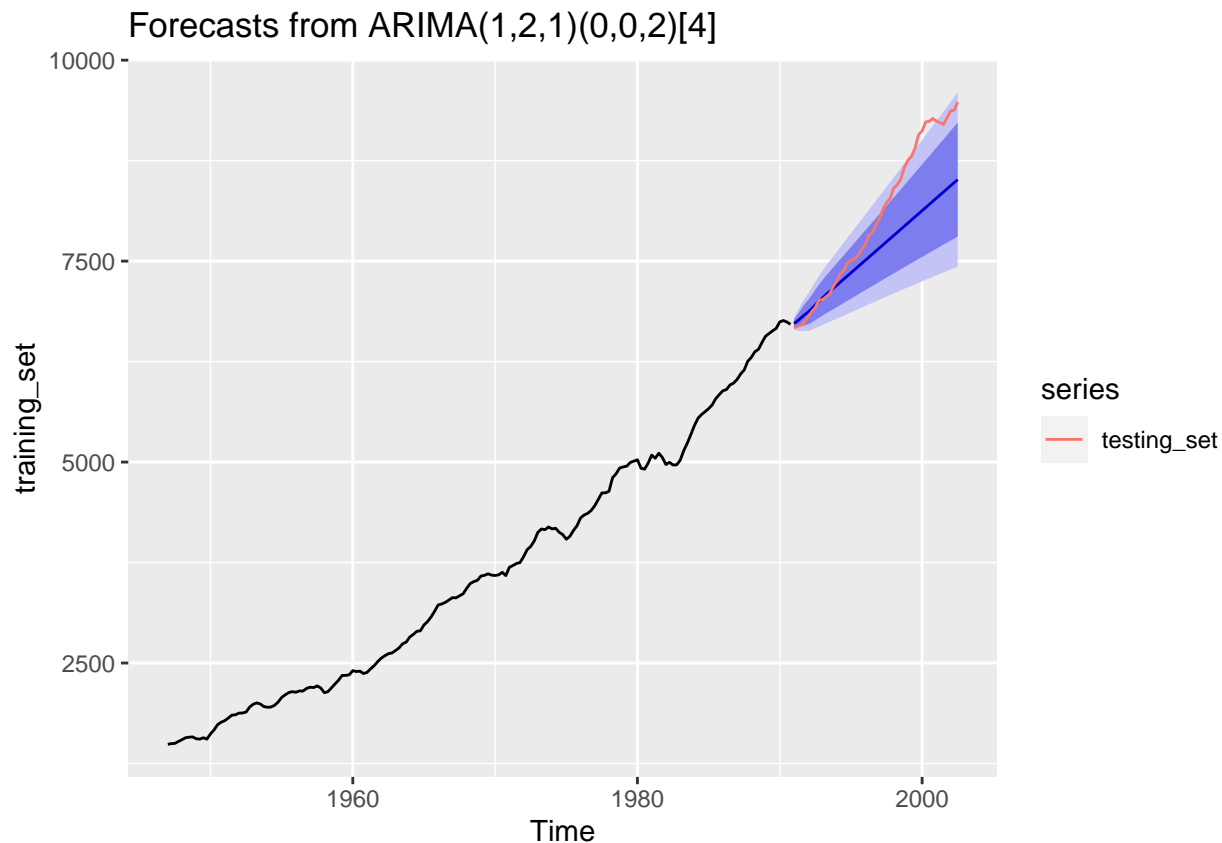
Widzimy, że model  $MA(21)$ , tak jak podejrzewaliśmy, nie ma zbyt dobrych własności predykcyjnych.

```
ar20.forecast <- forecast::forecast(ar20.fit, h = h)
autoplot(ar20.forecast) + autolayer(testing_set)
```



Model  $AR(20)$  jest trochę lepszy, ale wyniki wciąż są daleko od zadowalających.

```
arima.forecast <- forecast::forecast(arima.fit, h = h)
autoplot(arima.forecast) + autolayer(testing_set)
```



Model dopasowany automatycznie ma najlepsze zdolności predykcyjne, ale wciąż fragmenty estymowanego szeregu czasowego wychodzą poza przedziały ufności.

## Ocena dokładności

```
accuracy(ma21.forecast, testing_set)
```

	ME	RMSE	MAE	MPE	MAPE	MASE
## Training set	12.72106	37.83228	28.50615	0.3735088	0.8320866	0.2095082
## Test set	1290.02128	1579.36046	1291.98298	14.9387486	14.9681238	9.4955314

	ACF1	Theil's U
## Training set	-0.08010559	NA
## Test set	0.94834698	19.57703

```
accuracy(ar20.forecast, testing_set)
```

	ME	RMSE	MAE	MPE	MAPE	MASE
## Training set	3.677295	34.53522	26.4001	0.1235633	0.7906076	0.1940296
## Test set	688.475517	911.87895	699.7302	7.8219564	7.9895618	5.1427223

	ACF1	Theil's U
## Training set	-0.0104706	NA
## Test set	0.9527785	11.17093

```
accuracy(arima.forecast, testing_set)
```

	ME	RMSE	MAE	MPE	MAPE	MASE
## Training set	3.585384	36.04791	27.11557	0.1019004	0.796447	0.1992881

```
## Test set      422.892061 581.79252 443.81980 4.7621856 5.070063 3.2618889
##              ACF1 Theil's U
## Training set -0.04788432      NA
## Test set      0.95804352  7.123378
```

Patrząc na współczynniki błędów, potwierdzają się słowa powyżej jeśli chodzi o poprawność prognozy. Najlepszym modelem jest model dopasowany automatycznie, później model autoregresji oparty na analizowaniu funkcji cząstkowej autokorelacji, a najgorzej wypada model ruchomej średniej wyznaczony poprzez analizę funkcji autokorelacji.